

卒業論文

カメラ画像と目標方向を用いた End-to-End 学習による シナリオに基づく Navigation 手法の提案

An End-to-End Navigation Method for Route Selection on Branch Roads

Using Camera Images and Target Directions

2022 年 1 月 12 日 提出

指導教員 林原 靖男 教授

千葉工業大学 先進工学部 未来ロボティクス学科

18C1096 春山 健太

概要

カメラ画像と目標方向を用いた end-end 学習による
分岐路でのルート選択可能な navigation 手法の提案

本論文では、まとめたら追記します。

キーワード: end-to-end 学習, navigation, 模倣学習

abstract

An End-to-End Navigation Method for Route Selection on Branch Roads
Using Camera Images and Target Directions

In this paper,

keywords: end-to-end Learning, navigation, Imitation Learning

目次

第 1 章	序論	1
1.1	背景	1
1.2	目的	7
1.3	論文構成	7
第 2 章	要素技術	8
2.1	Deep learning	8
2.2	End-to-End 学習	9
2.3	Convolution Neural Network	10
第 3 章	提案手法	11
3.1	提案手法の概要	11
3.2	地図ベースの制御器	13
3.3	学習フェーズ	14
3.4	テストフェーズ	16
3.5	ネットワーク構造	17
第 4 章	実験	18
4.1	実験環境	18
4.2	実験方法	19
4.3	成功失敗条件	19
4.4	実験 1 十字路	20
4.4.1	実験目的	20

4.4.2 実験環境	20
4.4.3 学習フェーズでの経路	21
4.4.4 評価	21
4.5 実験 2 八の字	22
4.5.1 実験目的	22
4.5.2 実験環境	22
4.5.3 学習フェーズでの経路	23
4.5.4 評価	24
第 5 章 結論	26
参考文献	27
謝辞	28

図目次

1.1	Training the neural network from [6]	1
1.2	Okada and others proposed method from [9]	2
1.3	A robot that follows a path using vision based on the proposed method[9]	2
1.4	Cross Road	3
1.5	topo[5]	4
1.6	sina[5]	5
1.7	End-to-end Driving via Conditional Imitation Learning from [5]	6
1.8	Overview of Seiya and others proposed method from [8]	7
2.1	Neual Network	8
2.2	Structure of End-to-End learning	9
2.3	Alex net from [4]	10
3.1	turtlebot3 waffle	12
3.2	Concept of the proposed method	12
3.3	Map-based controller	13
3.4	Map-based controller	14
3.5	Learning phase system	15
3.6	Test phase system	16
3.7	Method network	17
4.1	turtlebot3 waffle	18
4.2	Experiment1 Course	20

4.3	Experiment 1 Route	21
4.4	Experiment2 Course	22
4.5	Experiment 2 route	23
4.6	Experiment 2 point number	24

表目次

3.1	Command	14
3.2	Parameters of deep learning	17
4.1	Number of successes Experiment 1 point	21
4.2	Number of successes Experiment2 point	25

第1章

序論

1.1 背景

近年，様々なセンサを用いた移動ロボットの自律移動に関する研究が盛んに行われており，その中でカメラ画像を用いてロボットへ自律移動を行わせる研究も行われている。Bojaski ら [6] は Fig. 1.1 で示す方法で，人間のハンドル操作によるステアリングの角度の模倣学習を行い，画像を用いて走行を行う方法を提案した。

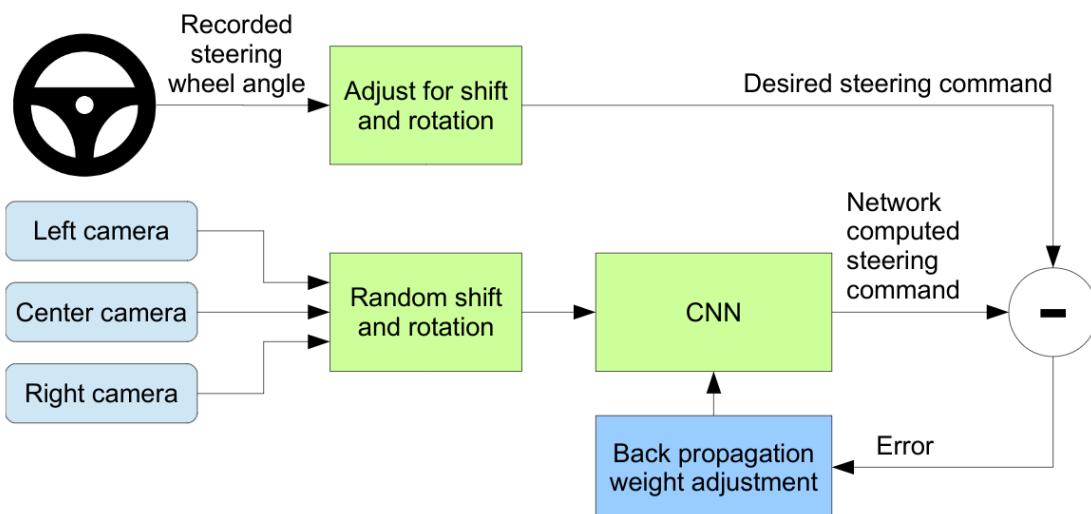


Fig. 1.1: Training the neural network from [6]

本研究室においても岡田ら [9] によって Fig. 1.2 に示すように LiDAR, オドメトリを入力としたルールベースの制御器の出力とその際に取得したカメラ画像を訓練データとして用いることで, 1.3 データセット収集における労力の削減, 経路へ戻る行動経路追従行動を模倣する手法を提案した。を確認した。




Fig. 1.2: Okada and others proposed method from [9]



Fig. 1.3: A robot that follows a path using vision based on the proposed method[9]

上記の研究により、カメラ画像用いて、ロボットが経路を周回可能であることが示されている。

経路を周回 研究の拡張を行う走行する経路内に Fig. 1.4 のような分岐路が含まれる場合、従来研究では同じ分岐路において任意のルートへ走行を明確に切り替え。

カメラ画像のみのでは「分岐路をどちらへ進むか」という特定のルート選択を行うために必要な情報が不足していることが要因と考えられる。画像のみを入力としたネットワークでは、

分岐路においてネットワークが2つの方向を出力してしまい、左右に車体を向ける振動が発生してしまう事象が Dean A. Pomerleau ら [7] によって確認されている。



Fig. 1.4: Cross Road

分岐路で経路を選択する情報として交差点などの目印に基づいて店まで移動することができる人間が「道案内」シナリオ 1.6 1.5 目印とそのつながりを表現する地図（トポロジカルマップ）トポロジカルマップとシナリオの情報を入力へ加えること

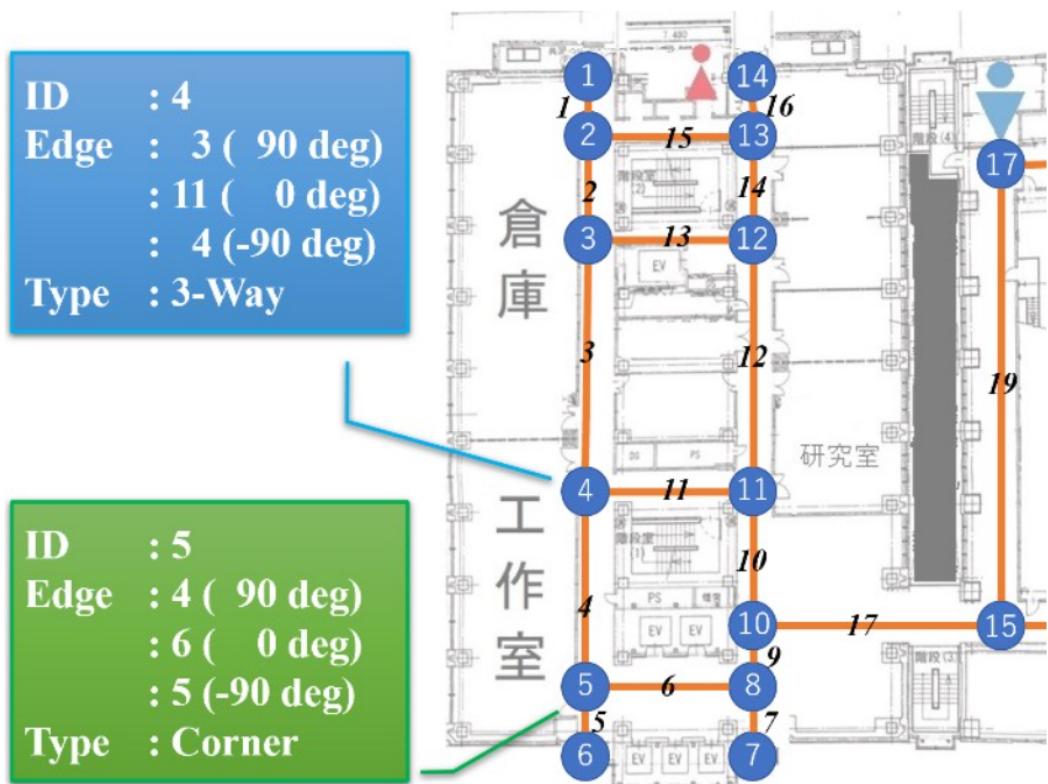


Fig. 1.5: topo[5]

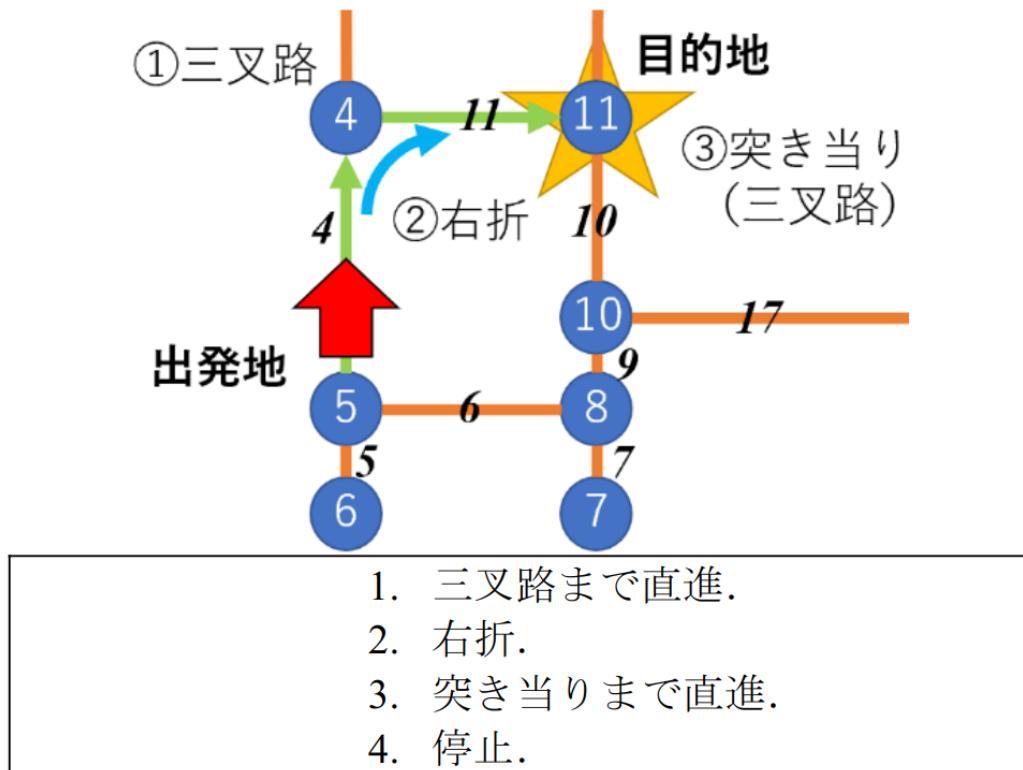



Fig. 1.6: sina[5]

本研究では、[9] らと島田ら手法を拡張し、「直進」「左折」「右折」などの目標とする方向情報（本研究では”目標方向”とする）を追加することで分岐路において特定のルート選択を行う「カメラ画像と目標方向の情報を用いて、分岐路において任意の走行経路を選択する手法」を提案する。

カメラ画像以外に他の情報を用いて、自律移動を行う研究として Felipe ら [5] はカメラ画像と操舵角と加速度の 2 次元の制御信号と、`continue`, `left`, `straight`, `right` の 4 つのコマンドを入力としたネットワークを用いて Fig. 1.7 で示すように実環境と都市環境のシミュレータ上で学習器がコマンドに沿った行動が可能であることを確認している。



(a) Aerial view of test environment

(b) Vision-based driving, view from onboard camera

(c) Side view of vehicle

Fig. 1.7: End-to-end Driving via Conditional Imitation Learning from [5]

また，Seiya ら [8] は Fig. 1.8 で示すようにカメラ画像と目標方向を入力，ステアリング制御信号を出力とするシステムを用いて，右および左に曲がる屋外の軌道を追跡可能であることを確認している．




Fig. 1.8: Overview of Seiya and others proposed method from [8]

1.2 目的

本研究では，岡田らと島田らの研究を拡張し，カメラ画像と目標方向を用いた End-to-End 学習によるシナリオに基づいた Navigation 手法を行う前段階として

カメラ画像と目標方向を入力とする学習器の出力を用いた走行において，目標方向によって分岐路で任意のルートへ走行経路を変更することを目指す．カメラ画像以外に分岐路での方向指示の情報を追加し，その情報を用いてルート選択が可能であるかの検証を行う．

1.3 論文構成

1 章では，本研究における背景，及び目的を述べた．2 章では，本研究で用いた深層学習の要素技術について述べる．3 章では，本研究で用いた手法と構築したシステムについて述べる．4 章では，構築したシステムを用いた実験を行う．5 章では，本研究の結論を述べる．

第2章

要素技術

本章では、本研究で用いた深層学習に関連した要素技術について述べる。

2.1 Deep learning

Deep learning は近年、自然言語処理など様々な分野で利用されている。人間の脳におけるニューロンの構造を数理モデル（パーセプトロン）を用いて再現したニューラルネットワークを多層構造にすることで、複雑なタスクの解決に必要な関数の表現力を高めたものである。一般的な構造を Fig. 2.1 示す。

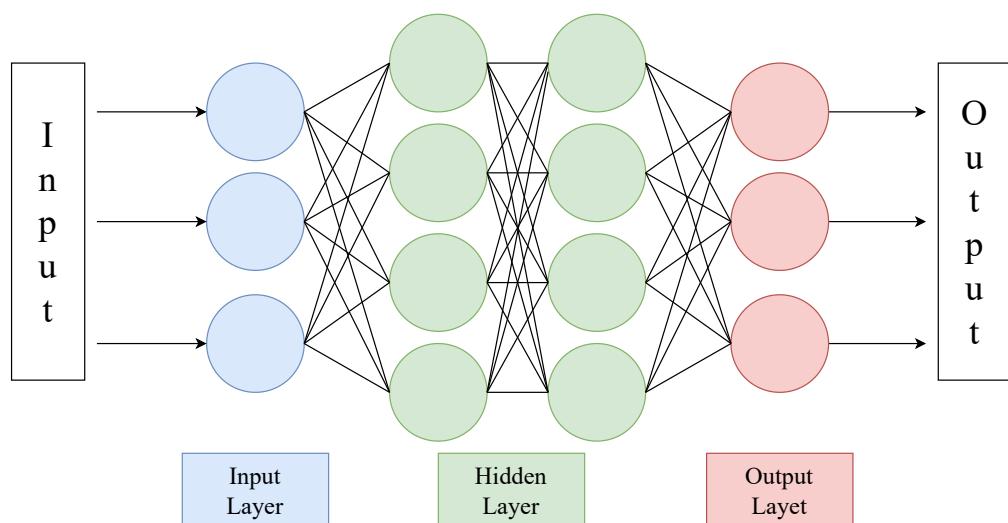


Fig. 2.1: Neural Network

2.2 End-to-End 学習

End-to-End とは「端から端まで」という、Fig. 2.2 に示すように生データ（入力）から目的の結果（出力）を得るために必要な多段階の処理を Neural Network を用いて直接学習を行うものである。例として、実世界における自動運転では人物や障害物などの物体認識、走行レンンの検出、経路計画、ステアリング制御などの人間が設定した複数個のタスクを解く必要があるが、End-to-End 学習では先程のタスクを人間が直接設定せずにカメラ画像をニューラルネットワークに入力することで直接ステアリング操作を学習する。

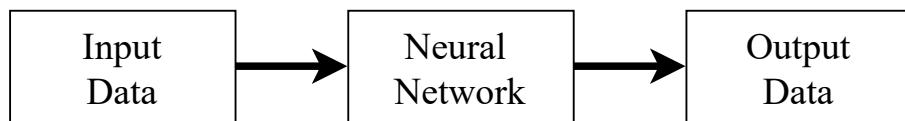


Fig. 2.2: Structure of End-to-End learning

2.3 Convolution Neural Network

畳み込みニューラルネットワーク (convolutional neural network:CNN) は画像認識や音声認識などの多次元の配列で表される複雑なデータを扱う処理へ用いられているニューラルネットワークである。次のような特徴をもつ層で構成されている。

1. 畳み込み層：入力データへフィルタ（カーネル）を用いて畳み込み演算を行うことで、特徴を抽出した特徴マップを取得する
2. プーリング層：Max プーリングなどの演算を用いて特徴マップのダウンサンプリングを行う
3. 全結合層：畳み込み層、プーリング層で行った特徴を抽出したデータを一つのノードに集約を行い、分類などの結果の出力をを行う

Krizhevsk ら [4] は Fig. 2.3 で示すような 3 つの畳み込み層 (convolutional layer) , 2 つのプーリング層 (pooling layer) および 3 つの全結合層 (fully connected layer) から構成したネットワークを用いて、120 万の高解像度画像を 1,000 の異なるクラスに分類をエラー率 15.3% で達成し、画像分類コンペティションである ILSVRC (ImageNet Large Scale Visual Recognition Competition) 2012 で優勝をおさめた

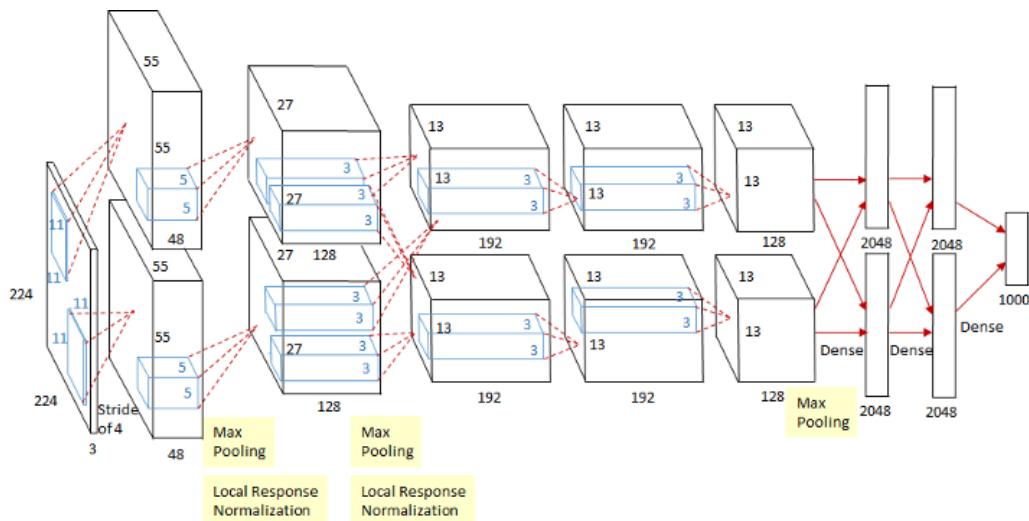


Fig. 2.3: Alex net from [4]

第3章

提案手法

本章では、提案手法の概要、及び提案手法に基づいて構築したシステムを学習器の訓練に用いる地図ベースの制御器、学習フェーズ、テストフェーズの4節に分けて述べる。

3.1 提案手法の概要

1章の背景で述べた分岐路において、ルートを選択する場合に入力する情報としてカメラ画像のみでは「右と左のどちらに曲がる」という判断をするための情報が不足していると考えられる。そこで、カメラ画像をもとに End-to-End 学習で経路追従行動を行う岡田らの研究 [9] で用いたシステムへカメラ画像以外にルートの選択に必要な情報として、「直進」「左折」「右折」の目標方向情報をコマンドを追加した、

本研究で対象とするロボットの構造、搭載するセンサを 3.1 とし、提案手法の概要を以下に示す 3.2 学習フェーズ?? テストフェーズ??

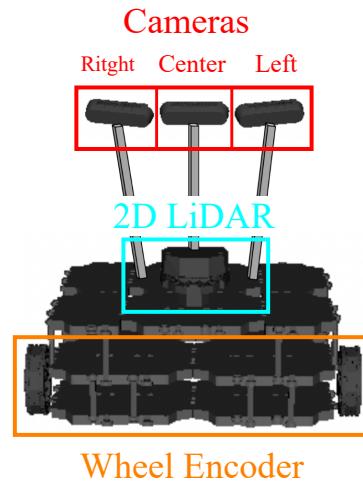
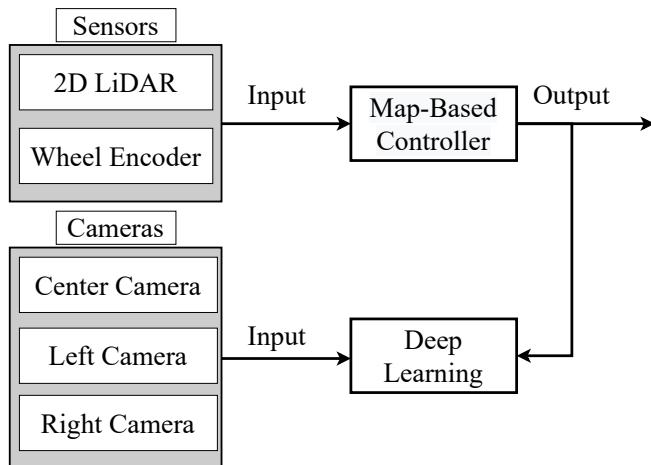



Fig. 3.1: turtlebot3 waffle



(a) Learning phase



(b) Test phase

Fig. 3.2: Concept of the proposed method

3.2 地図ベースの制御器

学習フェーズで使用する地図ベースの制御器について、概要を Fig. 3.3 に示す。センサからの観測情報を用いて局所的な障害物認識を行う local_costmap, local_costmap の結果を利用して局所的な経路計画を行う local_planner。後述する map_server から配信される、地図に対して全体のコスト計算を行う global_costmap。その結果を利用して大域的な経路計画を行う global_planner。これらを統合して行動計画とモータ指令を行う「move_base」、Particle_Filter によって自己位置推定を行う「amcl」、この 2 つへ保持する地図の配信を行う「map_server」などのパッケージを統合した自律移動用のメタパッケージである。ROS Navigation_stack[2] へ目標地点 (waypoint) と目標方向の生成機能をもつ「waypoint_nav」を組み込んで使用している。目標方向は「道なり」「直進」「左折」「右折」の 4 つとし、要素数 4、次元数 1 の int 型の配列 (One-Hot ベクトル) で表現する。方向と配列の対応を Table 3.1 に示す。




Fig. 3.3: Map-based controller

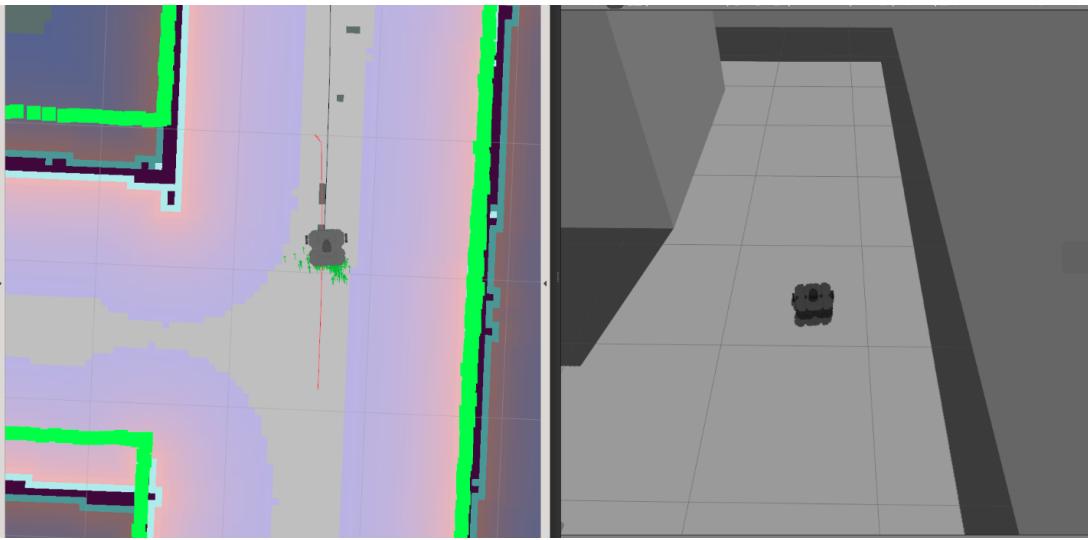


Fig. 3.4: Map-based controller

Table 3.1: Command

Target Direction	con	go straihg	go left	go right
data	[100, 0, 0, 0]	[0, 100, 0, 0]	[0,0,100, 0]	[0, 0, 0, 100]

3.3 学習フェーズ

学習器の訓練を行う学習フェーズで用いるシステムを Fig. 3.5 示す。学習は下記の一連の流れを 1step として、設定した step 数行う。

1. LiDAR とオドメトリを入力とする地図ベースの制御器の出力を用いて自律走行を行う
2. 地図ベースの制御器の出力からヨー方向の角速度とコマンド、機体に取り付けたカメラから RGB 画像を取得し、訓練データへ加える
3. 訓練データを 入力:カメラ画像、コマンド 目標出力:角速度 として学習器へ渡す
4. 学習器の出力を記録。

画像の取得には従来研究 [9] にならい、機体の中央、中央に対して左、右に傾けて取り付けた 3 つのカメラを用いる。

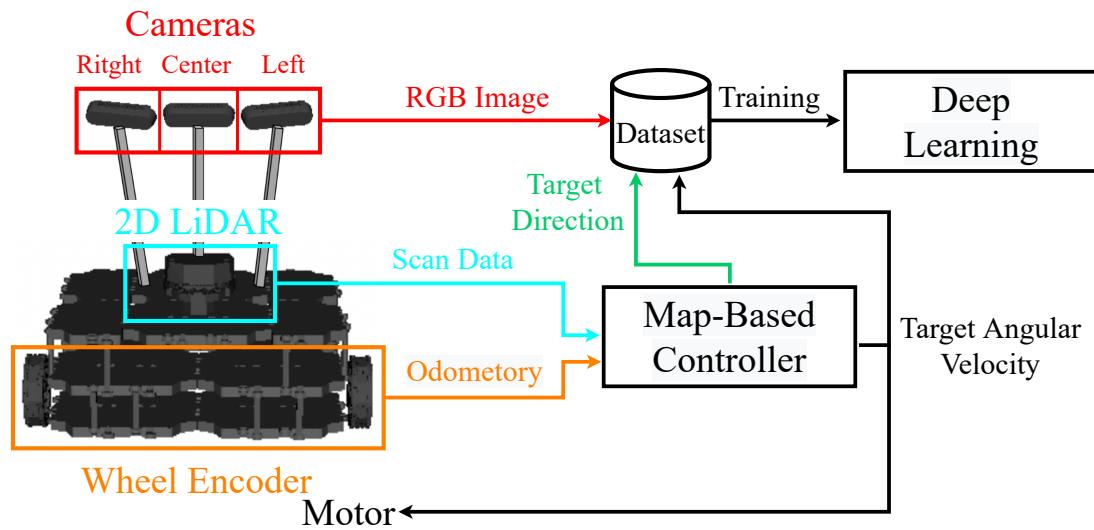


Fig. 3.5: Learning phase system

3.4 テストフェーズ

設定した step 数に達した場合に , Fig. 3.6 に示すように地図ベースの制御器の出力による動作から , 中央のカメラ画像とコマンドを入力とした学習器の出力による動作へ切り替えて走行を行う . テスト時のコマンドの生成 (方向の指示) は Joy_stick コントローラのボタンを用いて行う . テストフェーズにおける手順を下記に示す .

1. 機体に取り付けた中央のカメラから RGB 画像,Joy_stick コントローラよりコマンドのデータを取得
2. 取得したデータ (カメラ画像 , コマンド) を学習器へ入力
3. 学習器の出力である角速度をモータへ与える




Fig. 3.6: Test phase system

3.5 ネットワーク構造

今回のシステムで用いたネットワークを Fig. 3.7 に示す。また、ハイパー-パラメータについて Table 3.2 に示す。 64×48 の RGB 画像を入力とする入力層 1，畳込み層 3，全結合層 2 層を持つ 6 層の CNN と，CNN の出力とコマンドを入力する入力層 1，全結合層 2。出力層 1 の全 10 層の構造になっている。出力はヨー方向の角速度を連続値である。

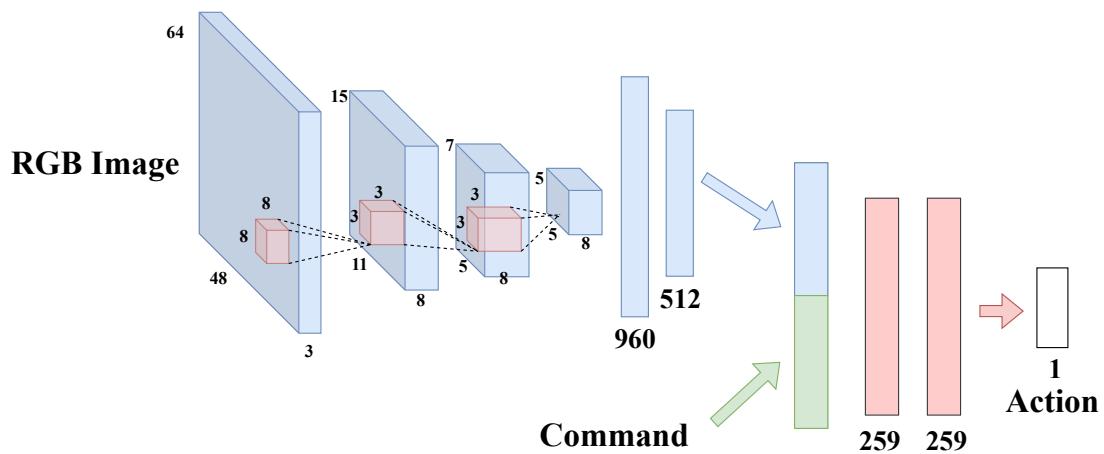


Fig. 3.7: Method network

Table 3.2: Parameters of deep learning

Input Data	Image (64×48 pixels, RGB channels) , Command
Optimizer	Adam ($\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 1e^{-1}$)
Loss Function	Softmax-cross-entropy
Output Data	Angular velocity

第4章

実験

4.1 実験環境

実験はシミュレータ上で行い，シミュレータ環境としてオープンソースの3DロボットシミュレータGazebo[1]を用いる．使用機体についてはturtlebot3_waffle[3]へカメラを3つ追加したモデル4.1を使用する．




Fig. 4.1: turtlebot3 waffle

4.2 実験方法

実験における手順を下記に示す

1. 学習フェーズを行い，学習器の訓練（経路の学習）行う
(制御：地図ベースの制御器の出力)
2. 設定した step 数を学習後，訓練フェーズへ移行
(制御：学習器の出力)
3. コース内に設定した地点において目標方向のコマンドを入力，挙動を確認

実験はコース内に設定した地点ごとにコマンドの入力による挙動の確認を 5 回ずつ行う。
また，用いるコースは実験ごとに異なるものを用いる。

4.3 成功失敗条件

実験の評価条件を下記のように定義する

成功：分岐路において壁に衝突せず，コマンドに対応したコースを選択

失敗：コマンドとは異なったコースを選択する，分岐路において壁に衝突

4.4 実験1 十字路

4.4.1 実験目的

提案手法を用いて、分岐路においてコマンドによってルートの変更が可能であるかの検証を行う。

4.4.2 実験環境

学習 step 数:4000[step] Fig. 4.2 に示す道幅が 2.5m 幅の十字路の環境を用いる。




Fig. 4.2: Experiment1 Course

4.4.3 学習フェーズでの経路

学習時の経路について Fig. 4.3 に示す Fig 内の緑で示す箇所が初期位置 , 赤で示す円が目標地点である目標地点を 1,2,3 の順で走行し , 到達後初期値点ヘロボットの位置 , 姿勢をリセットする .

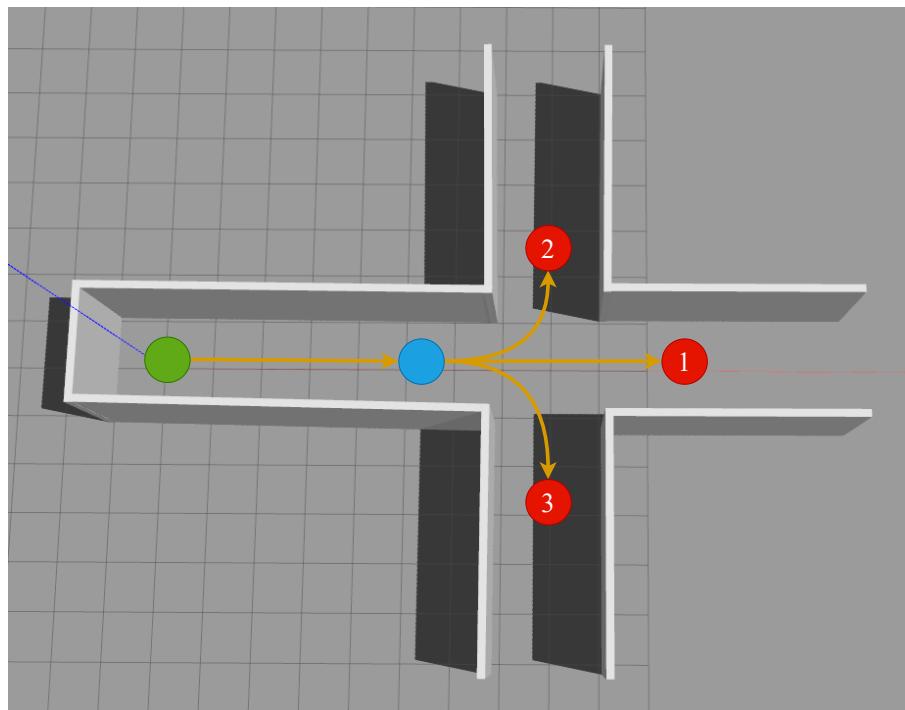


Fig. 4.3: Experiment 1 Route

4.4.4 評価

Fig. 4.3 で青で示した地点において , コマンドを入力を行った結果を Table. 4.1 に示す .

Table 4.1: Number of successes Experiment 1 point

Point	Number of successes
1	/5
2	/5
3	/5

4.5 実験2 八の字

4.5.1 実験目的

実験1で用いた局所的な環境を更に複雑な環境へ拡張し、提案手法を用いて、分岐路においてコマンドによってルートの変更が可能であるかさらなる検証を行う。

4.5.2 実験環境

学習 step 数:60000step Fig. 4.4 に示す道幅が 2.5m 幅の八の字型の環境用いる。

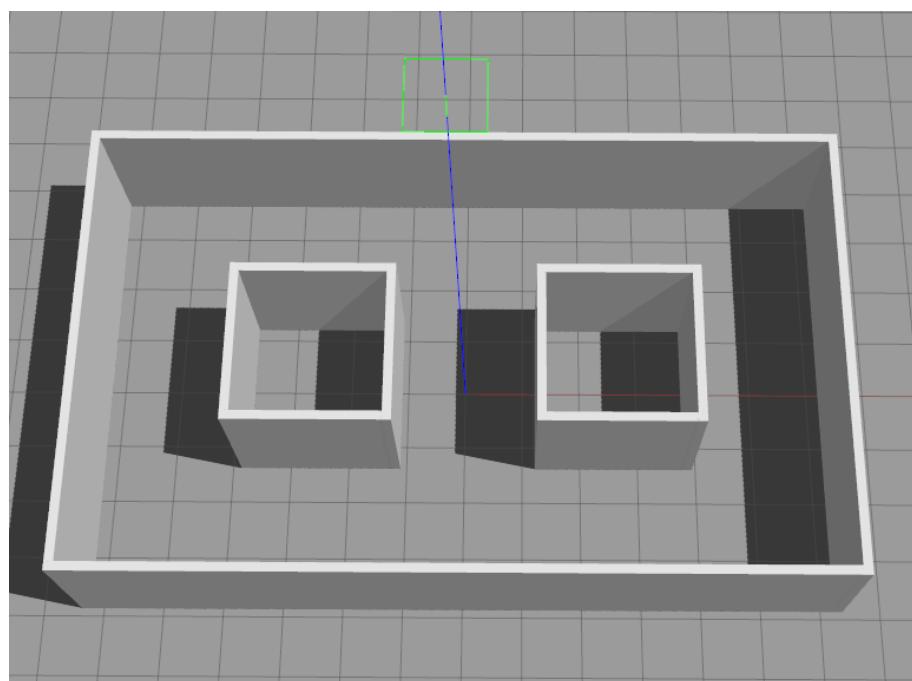


Fig. 4.4: Experiment2 Course

4.5.3 学習フェーズでの経路

学習時の経路について Fig. 4.5 に示す。Route 1-6 のルートを繰り返し周回する。

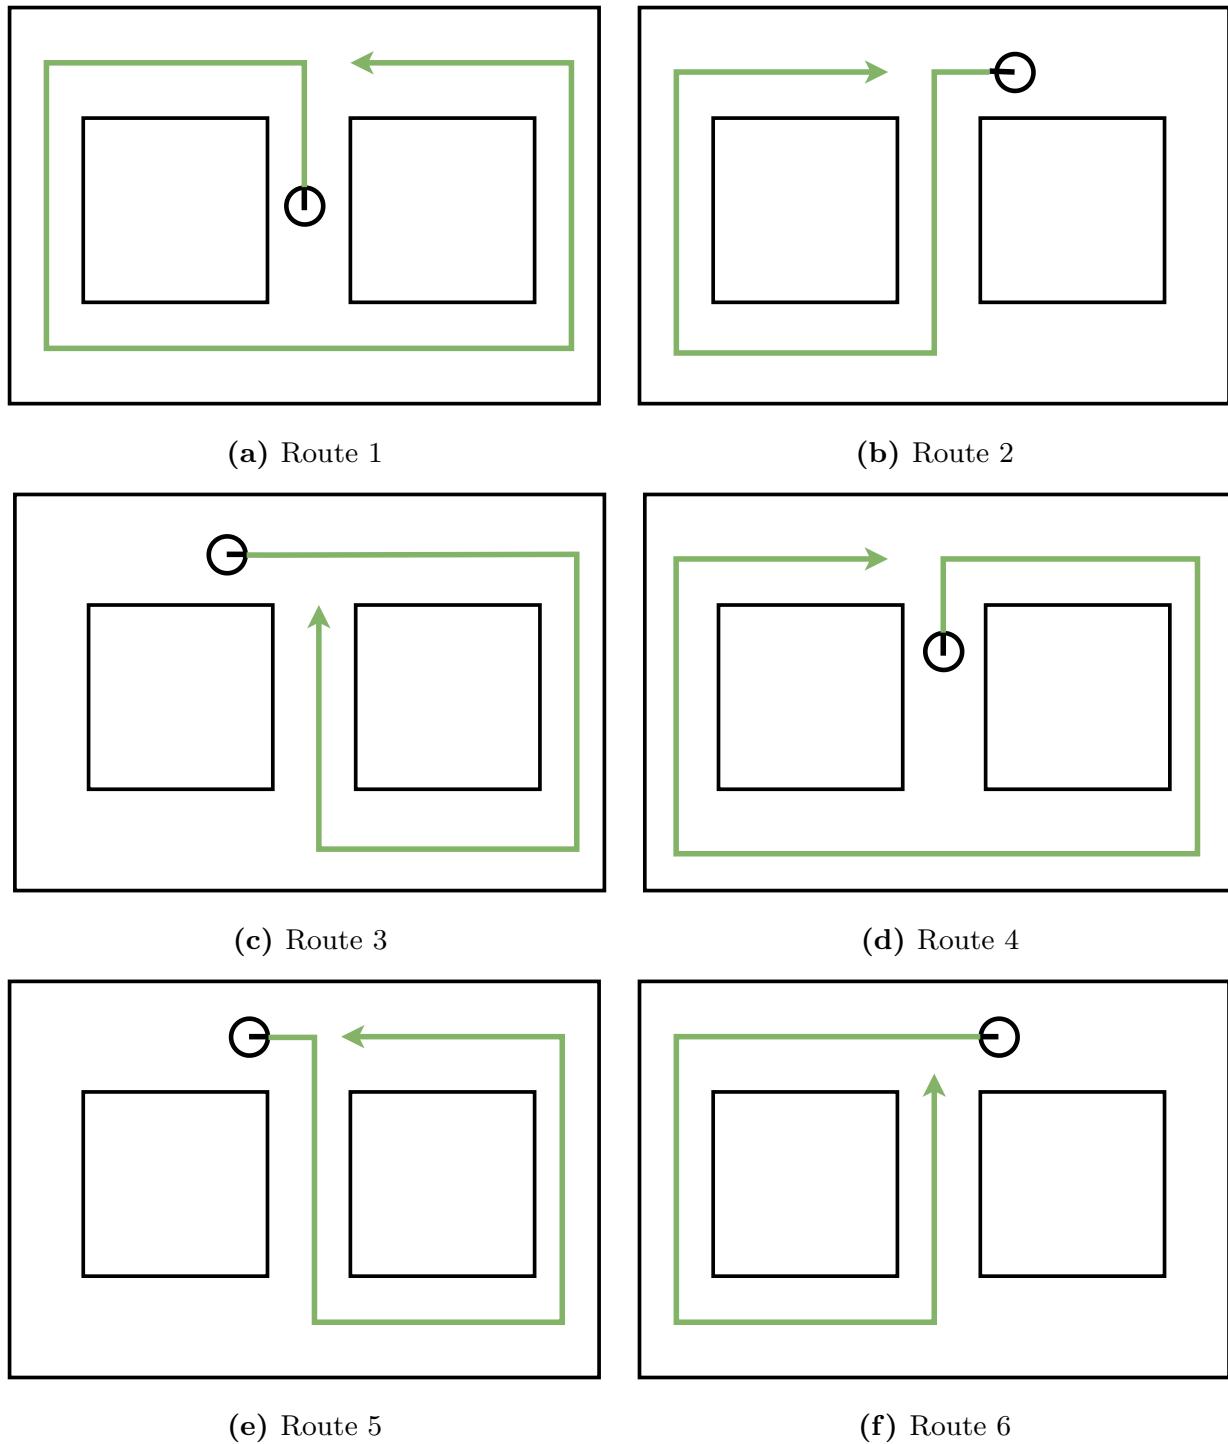


Fig. 4.5: Experiment 2 route

4.5.4 評価

コース内の各地点へ Fig. 4.6 で示すように番号をふり，地点ごとの成功回数を Table. 4.2 に示す．

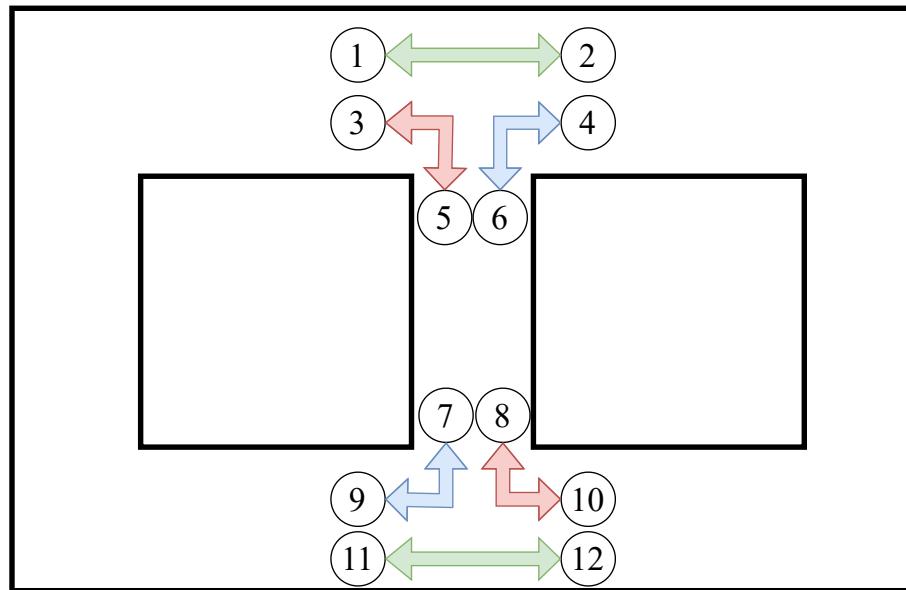


Fig. 4.6: Experiment 2 point number

Table 4.2: Number of successes Experiment2 point

Point	Number of successes
1	/5
2	/5
3	/5
4	/5
5	/5
6	/5
7	/5
8	/5
9	/5
10	/5
11	/5
12	/5

第5章

結論

本研究では、岡田ら [9] らのカメラ画像を用いて経路追従行動を行う手法を拡張し、カメラ画像とコマンドを用いた分岐路で任意のルートを選択する手法を提案し、シミュレータを用いて検証を行った。

あとはまとまり次第書きます

参考文献

- [1] gazebo. <http://gazebosim.org/>. (Accessed on 12/30/2021).
- [2] ros-planning, navigation. <https://github.com/ros-planning/navigation>. (Accessed on 12/30/2021).
- [3] Turtlebot3 — robotis emanual.robotis. <https://emanual.robotis.com/docs/en/platform/turtlebot3/overview/>. (Accessed on 12/31/2021).
- [4] I. Sutskever A. Krizhevsky and G. E. Hinton. Imagenet classification with deep convolutional neural networks. pages 2P1–J07. 一般社団法人 日本機械学会, 2017.
- [5] Felipe Codevilla et al. ”end-to-end driving via conditional imitation learning”. arXiv: 1710.02410, 2018.
- [6] Mariusz Bojarski et al. ”end to end learning for self-driving cars”. arXiv: 1604.07316, 2016.
- [7] Dean A. Pomerleau. Alvinn: An autonomous land vehicle in a neural network. In D. Touretzky, editor, *Advances in Neural Information Processing Systems*, volume 1. Morgan-Kaufmann, 1989.
- [8] Shunya Seiya, Alexander Carballo, Eijiro Takeuchi, Chiyomi Miyajima, and Kazuya Takeda. ”end-to-end navigation with branch turning support using convolutional neural network”. In *2018 IEEE International Conference on Robotics and Biomimetics (ROBIO)*, pages 499–506, 2018.
- [9] 上田隆一 林原靖男 岡田眞也, 清岡優祐. ”視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案”. In *SICE-SI2020 予稿集*, pages 1147–1152. 制御学会 SI 部門講演会, 2020.

謝辞

本研究を進めるにあたり，，熱心にご指導していただいた林原靖男教授に深く感謝いたします。また，研究の礎や研究へのアドバイスなどの様々な面で，指導，サポートしてくださった岡田眞也様，清岡優祐様には返しきれぬ恩をいただきました。日々の生活の中で，議論や意見をしていただいたロボット設計制御研究室の皆様と精神的に辛い際の支えであり，生活に潤いをくださった私の彼女へ感謝いたします。

最後に私を育てていただいた両親へ謝意を表します。